

8. Strojové učení.

Strojové učení

- Učení s učitelem (Supervised learning)
- Učení bez učitele (Unsupervised learning)
- Posilované/motivované učení (Reinforcement learning)

Pozn.: Učení je přirozenou vlastností umělých neuronových sítí, jejichž popis je jednou z hlavních náplní magisterského předmětu SFC (Soft-Computing).

Učení s učitelem (supervised learning)

- Tvorba rozhodovacích stromů (Decision Trees Building)
- Prohledávání prostoru verzí (Version Space Search)
- Rozpoznávání/klasifikace obrazů (Pattern Recognition)


Rozhodovací stromy - Tvorba modelu

- model popisuje vztahy mezi pozorovanými veličinami ($X_1, X_2, X_3, \dots, X_n, Y$)
- získání sady dat (např. měření)
 - každé veličině (proměnné) je přiřazena hodnota
 - jedno pozorování = příklad, objekt
- proces učení podle sady pozorování (příkladů, objektů)
 - vytvoření modelu
 - validace modelu
 - kalibrace modelu

Cíl modelu: Definovat vztah mezi závislou proměnnou (Y) a vysvětlujícími proměnnými (prediktory, vlastnostmi) (X_i) s cílem odvodit hodnotu závislé proměnné podle hodnot prediktorů.

	Příjem	Historie úvěrů	Dluh	Ručení	Risk úvěru
1	< 15	špatná	vysoký	žádné	vysoký
2	15 – 35	neznámá	vysoký	žádné	vysoký
3	15 – 35	neznámá	nízký	žádné	přiměřený
4	< 15	neznámá	nízký	žádné	vysoký
5	> 35	neznámá	nízký	žádné	nízký
6	> 35	neznámá	nízký	adekvátní	nízký
7	< 15	špatná	nízký	žádné	vysoký
8	> 35	špatná	nízký	adekvátní	přiměřený
9	> 35	dobrá	nízký	žádné	nízký
10	> 35	dobrá	vysoký	adekvátní	nízký
11	< 15	dobrá	vysoký	žádné	vysoký
12	15 – 35	dobrá	vysoký	žádné	přiměřený
13	> 35	dobrá	vysoký	žádné	nízký
14	15 – 35	špatná	vysoký	žádné	vysoký

Ukázka rozhodovacího stromu:



Typy proměnných

- kvalitativní (kategoriální): výčet kategorií, nelze porovnávat
- semikvalitativní (ordinální): lze porovnat, určit pořadí
- kvantitativní (spojitá)

Rozdělení metod


- klasifikační: klasifikace objektu do konečného počtu známých kategorií (tříd)
- regresní: závislá proměnná má kvantitativní charakter

Validační techniky

- rozdělení souboru dat na trénovací (80%) a testovací (20%)
- křížová validace: k podsouborů, 1 pro testování, k-1 pro tvorbu modelu; celkem vznikne k modelů

Stabilita stromů

- Stromy jsou obecně nestabilní metody (malá změna dat, může způsobit velké změny v rozhodovacích pravidlech)
- Problém nedoučení (malá množina pozorování) a přeučení (košatý strom)



Klasifikační rozhodovací stromy

- Slouží ke klasifikaci objektů na základě hodnot jejich vlastností
- Jsou vytvářeny ze známé množiny příkladů (učení pozorováním, dolování dat/znalostí)

Obecný algoritmus pro tvorbu rozhodovacích stromů je ukázán na následujícím snímku (procedura InduceTree).

InduceTree (obecný algoritmus pro tvorbu rozhodovacích stromů):

Vstupní parametry: Množina příkladů MP , Množina vlastností MV

1. Patří-li všechny prvky množiny příkladů MP do stejné třídy, vraťte listový uzel označený touto třídou, jinak pokračujte.
2. Je-li množina vlastností MV prázdná, vraťte listový uzel označený disjunkcí všech tříd, do kterých patří prvky v množině příkladů MP , jinak pokračujte.
3. Vyberte vlastnost V_i , odstraňte ji z množiny vlastností MV a učiňte ji kořenem aktuálního stromu (nechť MV_{-i} je množina vlastností MV bez vlastnosti V_i).
4. Pro každou hodnotu h_j vybrané vlastnosti V_i :
 - a. Vytvořte novou větev stromu označenou hodnotou h_j (nechť podmnožina příkladů MP_j je množina všech prvků množiny příkladů MP , které mají hodnotu h_j vlastnosti V_i),
 - b. Volejte rekurzivně InduceTree s parametry MP_j a MV_{-i} ,
 - c. Připojte vrácený podstrom/uzel k této větvi.

ID3 (Iterative Dichotomiser 3)

Algoritmus ID3 se liší od algoritmu InduceTree pouze tím, že jako vlastnost V_i (bod 3 algoritmu) vybere vždy tu vlastnost, která vede k největšímu informačnímu zisku.

Základní pojmy nutné pro pochopení činnosti algoritmu ID3:

Entropie (míra neurčitosti) zprávy M s n odpověďmi $\{m_1, m_2, \dots, m_n\}$, jejichž pravděpodobnosti výskytu jsou označeny jako $p(m_i)$, je dána výrazem:

$$E(M) = - \sum_{i=1}^n p(m_i) \log_2 p(m_i) \quad [bit]$$

Lze snadno odvodit, že dílčí entropie odpovědi m_j , která má nulovou pravděpodobnost výskytu ($p(m_j) = 0$), je také nulová

$$\lim_{p(m_j) \rightarrow 0} p(m_j) \log_2 p(m_j) = 0$$

a nijak neovlivňuje celkovou entropii zprávy.

Podobně nemají vliv na entropii zprávy ani odpovědi jisté ($p(m_k) = 1$)

$$p(m_k) \log_2 p(m_k) = 1 \cdot \log_2 1 = 0$$

Je také zřejmé, že entropie zprávy je maximální pro rovnoměrné rozložení pravděpodobností jednotlivých odpovědí

$$p(m_i) = \frac{1}{n}, \quad i = 1 \dots n$$

$$E(M) = - \sum_{i=1}^n \frac{1}{n} \log_2 \frac{1}{n} = - \log_2 \frac{1}{n} = \log_2 n$$

Je-li možné odpovědi zprávy M rozdělit podle nějaké vlastnosti V_i do k disjunktních podmnožin M_j

$$\bigcup_{j=1}^k M_j = M, \quad \bigcap_{j=1}^k M_j = \emptyset$$

pak pro entropii takto rozdělené (divided) zprávy $E(M_d)$ platí vztah

$$E(M_d) = \sum_{j=1}^k \frac{|M_j|}{|M|} E(M_j)$$

Informační zisk IG (Information Gain) zprávy M rozdělené do podmnožin M_j podle vlastnosti V_i je dán jednoduchým vztahem

$$IG(M, V_i) = E(M) - E(M_d) = E(M) - \sum_{j=1}^k \frac{|MP_j|}{|MP|} E(MP_j)$$

Demonstrační příklad: Z předchozích zkušeností zapsaných jako jednotlivé položky tabulky uvedené na dalším snímku, má bankovní úředník posoudit riziko úvěru pro nového klienta.

Poznamenejme, že tabulka obsahuje pouze necelou polovinu možných položek, jejichž maximální počet je dán součinem všech možných hodnot jednotlivých podmínkových atributů

$$m = \prod_{i=1}^k h_k = 3 \cdot 2 \cdot 2 \cdot 3 = 36$$

Počet všech možných „mapovacích“ funkcí je pak dán výrazem

$$N = h^m$$

kde h značí počet hodnot rozhodovacího atributu, tj. pro uváděný příklad

$$N = 3^{36} \cong 1.5 \cdot 10^{17}$$

	Příjem	Historie úvěrů	Dluh	Ručení	Risk úvěru
1	< 15	špatná	vysoký	žádné	vysoký
2	15 – 35	neznámá	vysoký	žádné	vysoký
3	15 – 35	neznámá	nízký	žádné	přiměřený
4	< 15	neznámá	nízký	žádné	vysoký
5	> 35	neznámá	nízký	žádné	nízký
6	> 35	neznámá	nízký	adekvátní	nízký
7	< 15	špatná	nízký	žádné	vysoký
8	> 35	špatná	nízký	adekvátní	přiměřený
9	> 35	dobrá	nízký	žádné	nízký
10	> 35	dobrá	vysoký	adekvátní	nízký
11	< 15	dobrá	vysoký	žádné	vysoký
12	15 – 35	dobrá	vysoký	žádné	přiměřený
13	> 35	dobrá	vysoký	žádné	nízký
14	15 – 35	špatná	vysoký	žádné	vysoký

Tabulku/množinu příkladů MP je možné považovat za zprávu M a jednotlivé příklady z této tabulky za odpovědi m_i . Pak platí:

$$MP = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14\}$$

$$MV = \{prijem, historie_uveru, dluh, ruceni\}$$

$$MP_{nizký_risk} = \{5, 6, 9, 10, 13\} \Rightarrow p_{nizký_risk} = 5/14$$

$$MP_{priměřený_risk} = \{3, 8, 12\} \Rightarrow p_{priměřený_risk} = 3/14$$

$$MP_{vysoký_risk} = \{1, 2, 4, 7, 11, 14\} \Rightarrow p_{vysoký_risk} = 6/14$$

a tedy entropie (míra neuspořádanosti) této tabulky je

$$\begin{aligned} E(MP) &= - \sum_{i=1}^3 p(m_i) \log_2 p(m_i) = \\ &= - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) - \frac{3}{14} \log_2 \left(\frac{3}{14} \right) - \frac{6}{14} \log_2 \left(\frac{6}{14} \right) = 1.531 \end{aligned}$$

Pro vlastnost $V_{prijem} = \langle 15/15-35 \rangle 35$ (1/2/3) platí:

$$MP = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14\}$$

$$MP_1 = \{1, 4, 7, 11\}, MP_2 = \{2, 3, 12, 14\}, MP_3 = \{5, 6, 8, 9, 10, 13\}$$

$$E(MP_1) = -\frac{4}{4} \log_2 \left(\frac{4}{4} \right) = 0$$

$$E(MP_2) = -\frac{2}{4} \log_2 \left(\frac{2}{4} \right) - \frac{2}{4} \log_2 \left(\frac{2}{4} \right) = 1$$

$$E(MP_3) = -\frac{5}{6} \log_2 \left(\frac{5}{6} \right) - \frac{1}{6} \log_2 \left(\frac{1}{6} \right) = 0.650$$

$$IG(MP, prijem) = E(MP) - \sum_{j=1}^3 \frac{|MP_j|}{|MP|} E(MP_j) =$$

$$= 1.531 - \frac{4}{14} E(MP_1) - \frac{4}{14} E(MP_2) - \frac{6}{14} E(MP_3) = 0.967$$

Pro vlastnost $V_{historie_uveru}$ (neznámá/špatná/dobrá, 1/2/3):

$$MP = \{1,2,3,4,5,6,7,8,9,10,11,12,13,14\}$$

$$MP_1 = \{2,3,4, 5,6\}, MP_2 = \{1,7,8,14\}, MP_3 = \{9,10,11,12,13\}$$

$$E(MP_1) = -\frac{2}{5} \log_2 \left(\frac{2}{5} \right) - \frac{1}{5} \log_2 \left(\frac{1}{5} \right) - \frac{2}{5} \log_2 \left(\frac{2}{5} \right) = 0.544$$

$$E(MP_2) = -\frac{1}{4} \log_2 \left(\frac{1}{4} \right) - \frac{3}{4} \log_2 \left(\frac{3}{4} \right) = 0.311 + 0.5 = 0.232$$

$$E(MP_3) = -\frac{3}{5} \log_2 \left(\frac{3}{5} \right) - \frac{1}{5} \log_2 \left(\frac{1}{5} \right) - \frac{1}{5} \log_2 \left(\frac{1}{5} \right) = 0.490$$

$$IG(MP, historie_uveru) = E(T) - \sum_{j=1}^3 \frac{|MP_j|}{|MP|} E(MP_j) =$$

$$= 1.531 - \frac{5}{14} E(MP_1) - \frac{4}{14} E(MP_2) - \frac{5}{14} E(MP_3) = 0.266$$

Informační zisk pro zbývající vlastnosti se vypočítá podobně:


$$IG(MP, dluh) = 0.063$$

$$IG(MP, ruceni) = 0.206$$


Předchozími výpočty algoritmus ID3 zjistí, že nejvyšší informační zisk přinese rozdělení množiny příkladů MP tabulky T podle hodnot vlastnosti *prijem*. Tato vlastnost bude proto vybrána jako kořen budovaného rozhodovacího stromu (jde o bod 3. na snímku 4). Pro snadnější orientaci budeme dále označovat vnořená volání algoritmu ID3 jako ID3(1), ID3(2), atd.

Pro první hodnotu vlastnosti *prijem* (<15) se podle bodu 4.a. algoritmu ID3 vytvoří nová/první větev stromu a podle bodu 4.b. se volá algoritmus ID3(1) s množinou příkladů $MP = MP_1 = \{1, 4, 7, 11\}$ a množinou vlastností $MV = \{historie_uveru, dluh, ruceni\}$.

Podle bodu 1. algoritmu ID3(1) se vrací listový uzel „vysoký risk“ a podle bodu 4.c. algoritmu ID3 se tato větev ukončí.



Pro druhou hodnotu vlastnosti *prijem* (15–35) se podle bodu 4.a. algoritmu ID3 vytvoří nová/druhá větev stromu a podle bodu 4.b. se volá algoritmus ID3(1) s množinou příkladů $MP = MP_2 = \{2, 3, 12, 14\}$ a množinou vlastností $MV = \{historie_uveru, dluh, ruceni\}$.



Výpočtem informačního zisku IG pro jednotlivé vlastnosti se zjistí, že tento zisk je největší pro vlastnost *historie_uveru*, a proto se tato vlastnost vybere jako počátek nového podstromu:

$V_{prijem} = 15-30$, $MP = \{2,3,12,14\}$, $E(MP) = 1$ (viz snímek 11):

$V_{historie_uveru}$ (špatná/neznámá/dobrá, 1/2/3):

$MP_1 = \{14\}$, $MP_2 = \{2,3\}$, $MP_3 = \{12\}$,

$$E(M_d) = \sum_{j=1}^3 \frac{|MP_j|}{|MP|} E(MP_j) = \frac{1}{4} E(MP_1) + \frac{2}{4} E(MP_2) + \frac{1}{4} E(MP_3) = 0.5$$

$$IG(MP, historie_uveru) = E(MP) - E(M_d) = 1 - 0.5 = 0.5$$

V_{dluh} (vysoký/nízký, 1/2):


$MP_1 = \{2,12,14\}$, $MP_2 = \{3\}$ $IG(MP, dluh) = 0.311$

V_{ruceni} (adekvátní/žádné, 1/2):


$MP_1 = \{\}$, $MP_2 = \{2,3,12,14\}$ $IG(MP, ruceni) = 0$

Pro první hodnotu vlastnosti *historie_uveru* (špatná) se podle bodu 4.a. algoritmu ID3(1) vytvoří nová/první větev podstromu a podle bodu 4.b. algoritmu ID3(1) se volá algoritmus ID3(2) s množinou příkladů $MP = \{14\}$ a množinou vlastností $MV = \{dluh, ruceni\}$.

Podle bodu 1. algoritmu ID3(2) se vrací listový uzel „vysoký risk“ a podle bodu 4.c. algoritmu ID3(1) se tato větev ukončí.



Pro druhou hodnotu vlastnosti *historie_uveru* (neznámá) se podle bodu 4.a. algoritmu ID3(1) vytvoří nová/druhá větev podstromu a podle bodu 4.b. se volá algoritmus ID3(2) s množinou příkladů $MP = \{2,3\}$ a množinou vlastností $MV = \{dluh, ruceni\}$.




Výpočtem informačního zisku IG pro jednotlivé vlastnosti se zjistí, že tento zisk je největší pro vlastnost *dluh* ($IG(MP, dluh) = 1$), která se proto vybere jako počátek dalšího podstromu.

Pro první hodnotu vlastnosti *dluh* (vysoký) se vytvoří nová/první větev podstromu a volá se algoritmus $ID3(3)$ s množinou příkladů $MP = \{2\}$ a množinou vlastností $MV = \{ruceni\}$, který vrátí listový uzel „vysoký risk“.

Podobně se postupuje pro druhou hodnotu vlastnosti *dluh* (nízký), kdy volaný algoritmus $ID3(3)$ pro $MP = \{3\}$ a $MV = \{ruceni\}$ vrátí listový uzel „přiměřený risk“.


Algoritmus ID3(2) tedy vrací podstrom




který se podle bodu 4.c. algoritmu ID3(1) připojí ke větvi *historie_uveru* = neznámá:




Pro třetí hodnotu vlastnosti *historie_uveru* (dobrá) se podle bodu 4.a. algoritmu ID3(1) vytvoří nová/třetí větev podstromu a podle bodu 4.b. se volá algoritmus ID3(2) s množinou příkladů $MP = \{12\}$ a množinou vlastností $MV = \{dluh, ruceni\}$. Algoritmus ID3(2) vrátí listový uzel „přiměřený risk“, který se podle bodu 4.c. algoritmu ID3(1) připojí ke větvi *historie_uveru* = dobrá



Tím končí činnost algoritmu ID3(1), který vrací vytvořený podstrom algoritmu ID3 a ten podle bodu 4.c. připojí vrácený podstrom ke druhé větvi budovaného stromu (prijem = 15–35)



Algoritmus ID3 pak vytvoří novou/třetí větev pro hodnotu vlastnosti *prijem* (>35) a podobným způsobem, jakým se budovala větev pro hodnotu ($15 - 35$) vlastnosti *prijem*, pak budování rozhodovacího stromu dokončí:




Vytvořený strom lze snadno převést na pravidla:

1. Má-li žadatel příjem nižší než 15 tis. Kč, je risk úvěru vysoký.
2. Má-li žadatel příjem mezi 15 až 35 tis. Kč, pak
 - a) je-li historie splácení jeho úvěrů špatná, je risk úvěru vysoký.
 - b) je-li historie splácení jeho úvěrů dobrá, je risk úvěru přiměřený.
 - c) je-li historie splácení jeho úvěrů neznámá, pak
 - je-li jeho dluh vysoký, je risk úvěru vysoký.
 - je-li jeho dluh nízký, je risk úvěru přiměřený.
3. Má-li žadatel příjem vyšší než 35 tis. Kč, pak
 - a) je-li historie splácení jeho úvěrů špatná, je risk úvěru přiměřený.
 - b) je-li historie splácení jeho úvěrů dobrá, je risk úvěru nízký.
 - c) je-li historie splácení jeho úvěrů neznámá, je risk úvěru nízký.

Učení bez učitele (unsupervised learning)

Cílem je odhalit skrytou strukturu v neoznačených datech jejich uspořádáním do smysluplných skupin (shluků):



Shlukování (clustering)

Existuje řada různých algoritmů, nejznámější z nich je algoritmus ***k – means clustering*** (shlukování do k shluků).

Algoritmus je založen na předpokladu, že n -rozměrné vektory popisující neznámá data $\vec{x} = (x_1, x_1, \dots, x_n)$, resp. koncové body těchto vektorů, tvoří v n -rozměrném prostoru k shluků a že každý shluk i je reprezentován prototypem (vektorem „těžiště“ shluku) $\vec{w}_i$.

Algoritmus dále předpokládá, že do k shluků má rozdělit p vektorů z trénovací množiny $T = \{\vec{x}_1, \vec{x}_1, \dots, \vec{x}_p\}$.

Pozn.: Na výsledek učení má vliv použitá metrika – Euklidovská, Hammingova, atd.

Algoritmus k – means clustering

1. Inicializujte k prototypů $\vec{w}_j$ (použijte například náhodně vybrané, ale různé vektory $\vec{x}_p$ z trénovací množiny P vektorů, tj. $\vec{w}_j = \vec{x}_p$, $j \in \langle 1, k \rangle$, $p \in \langle 1, P \rangle$).
2. Každý vektor $\vec{x}_p$ z trénovací množiny přiřad'te do shluku C_j , $j \in \langle 1, k \rangle$, jehož prototyp $\vec{w}_j$ má od vektoru $\vec{x}_p$ nejmenší vzdálenost, tj.


$$|\vec{x}_p - \vec{w}_j| \leq |\vec{x}_p - \vec{w}_i|, \quad i \in \langle 1, k \rangle$$

1. Pro každý shluk C_j $j \in \langle 1, k \rangle$ přepočítejte prototyp $\vec{w}_j$ tak, aby byl těžištěm koncových bodů všech vektorů, které jsou k tomuto shluku právě přiřazené (nechť n_j je počet těchto vektorů):


$$\vec{w}_j = \frac{\sum_{\vec{x}_i \in C_j} \vec{x}_i}{n_j}$$

4. Pokud byl některý vektor přeřazen k jinému shluku, vraťte se na bod 2, jinak činnost algoritmu ukončete.


Příklad:




Výsledek získaný metodou k-means:



Nevhodně zvolené počáteční prototypy mohou vést k jiným a ne zcela očekávaným výsledkům:



Možné rozdělení do menšího požadovaného počtu shluků:




Posilované/motivované učení (reinforcement learning)

- Policy-only learning
- TD – learning (Temporal Difference learning)
- Q – learning
- SARSA

Agent ohodnocuje své akce na základě penalizací či odměn v koncových stavech, resp. na základě svých ocenění stavů/akcí získaných vlastními předchozími zkušenostmi.

Policy-only learning

Uvažujme nejprve jednoduchý graf, ve kterém z každého uzlu vedou maximálně dvě cesty a hledejme (optimální) cestu z počátečního do cílového uzlu. Každý rozcestník (signpost) obsahuje schránku/box s černými a bílými kameny, které se využívají k určení směru cesty:



- Na začátku učení obsahuje schránka každého rozcestníku stejný počet černých a bílých kamenů ($N_{bílý} = N_{černé}$).
- V průběhu učení jsou pravděpodobnosti pohybu agenta na každém rozcestníku dány výrazy:

$$p_{vlevo} = \frac{N_{bílý}}{N_{bílý} + N_{černé}}$$

$$p_{vpravo} = \frac{N_{černé}}{N_{bílý} + N_{černé}}$$


- Vyhodnocení cesty a odměna/penalizace:

Cesta vedla do cíle H $\Rightarrow$ odměna (přidání kamenů odpovídajících barev do boxů všech rozcestníků na příslušné cestě)

Cesta vedla do G, I, J $\Rightarrow$ penalizace (odebrání kamenů odpovídajících barev z boxů všech rozcestníků na příslušné cestě)

Pravděpodobnost výběru optimální cesty do H se zvyšuje,
pravděpodobnost výběru ostatních cest se snižuje !!!

Rozšíření popsaného principu posilovaného učení na problémy s více možnými cestami je snadné – použijí se pouze různobarevné kameny. Barvy mohou být zcela libovolné, musí však být jednoznačně přiřazeny k některé výchozí hraně každého uzlu):



Metoda Policy-only je sice jednoduchá, ale její použití může vést k několika problémům:

- V případě obecného grafu, kdy se lze vracet do již dříve vyšetřovaných uzlů, je nutné těmto „návratům“ zabránit.
- Ohodnocení rozcestníků se mění až při dosažení koncových stavů (těmito jsou obecně i konce slepých cest).
- Stejnými vahami se ohodnocují všechny akce provedené na jedné cestě, přičemž správná ohodnocení mohou být značně rozdílná.
- V paměti se musí ukládat úplné cesty, což může být u rozsáhlých úloh problematické.

TD learning (On-Policy)

Metoda postupně ohodnocuje během náhodné procházky jednotlivé stavy s (**stav s je vždy bezprostředním předchůdcem stavu s'**) pomocí vztahu:

$$U^\pi(s) = U^\pi(s) + \alpha(r(s') + \gamma U^\pi(s') - U^\pi(s)),$$

kde značí:

- $U^\pi(s)$ ohodnocení (*utility*) stavu s při použití strategie (policy) pohybu π (ze stavu s do stavu s').
- $r(s)$ odměnu (*reward*) za dosažení stavu s .
- γ koeficient určující vliv ohodnocení stavu s' na ohodnocení předcházejícího stavu s .
- α koeficient učení, jehož hodnota může klesat s počtem průchodů stavem s .

Strategie π : Tabulka pravděpodobností přechodů mezi jednotlivými stavy.

- Pravděpodobnosti přechodů mezi sousedními stavy jsou stejné a do sousedních stavů přechází zcela náhodně (random policy).
- Pravděpodobnosti jsou různé (mohou být například dány aktuálními hodnotami sousedních stavů, tj. čím je vyšší ohodnocení sousedního stavu, tím je vyšší pravděpodobnost přechodu do tohoto stavu).
- Pravděpodobnost jednoho přechodu je jedničková a pravděpodobnosti ostatních nulové, což je extrémní případ předchozího stavu (greedy policy).
- Kombinace předchozích případů, kdy s pravděpodobností danou parametrem ϵ se použije random policy a s pravděpodobností $(1 - \epsilon)$ se použije greedy policy (ϵ -greedy policy).

Algoritmus TD learning

1. Zvolte hodnoty koeficientů α a γ ($0 < \alpha \leq 1$; $0 < \gamma \leq 1$) a vynulujte ohodnocení $U^\pi(s)$ všech stavů. Dále vynulujte počítadlo procházek $p = 0$ a nastavte jejich maximální počet p_{max} . Nastavte $start \rightarrow s$.
2. Generujte nový stav s' s použitím strategie π .
3. Vypočítejte novou hodnotu stavu pomocí vztahu:
$$U^\pi(s) = U^\pi(s) + \alpha(r(s') + \gamma U^\pi(s') - U^\pi(s)),$$
4. Je-li stav s' cílovým stavem, pak $p+1 \rightarrow p$, $start \rightarrow s$, jinak $s' \rightarrow s$.
5. Je-li $p < p_{max}$, pak se vraťte na bod 2.

Příklad:

1			
2			
3			
	1	2	3

Nechť $r(3,2) = -1$ (penalizace v nežádoucím cíli), $r(3,3) = 1$ (odměna v žádoucím cíli) a všechna ostatní $r(i,j) = 0$.

Jednotlivé náhodné procházky mohou startovat odkudkoliv, pro jednoduchost předpokládejme, že všechny budou startovat ze stavu $(1,1)$. Dále necht' $\gamma = 0.9$ a $\alpha = 0.1$.

Uvažujme následujících pět náhodných procházek:

1. $(1,1) \rightarrow (1,2) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (3,3)$
2. $(1,1) \rightarrow (1,2) \rightarrow (2,2) \rightarrow (1,2) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (3,3)$
3. $(1,1) \rightarrow (2,1) \rightarrow (1,1) \rightarrow (1,2) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (3,3)$
4. $(1,1) \rightarrow (2,1) \rightarrow (3,1) \rightarrow (3,2)$
5. $(1,1) \rightarrow (2,1) \rightarrow (2,2) \rightarrow (3,2)$

Nejprve se všechna ohodnocení $U(i,j)$ vynulují.

První náhodná procházka $(1,1) \rightarrow (1,2) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (3,3)$:

$$U(1,1) = U(1,1) + \alpha \cdot (r(1,2) + \gamma \cdot U(1,2) - U(1,1)) = 0$$

$$U(1,2) = U(1,2) + \alpha \cdot (r(1,3) + \gamma \cdot U(1,3) - U(1,2)) = 0$$

$$U(1,3) = U(1,3) + \alpha \cdot (r(2,3) + \gamma \cdot U(2,3) - U(1,3)) = 0$$

$$\begin{aligned} U(2,3) &= U(2,3) + \alpha \cdot (r(3,3) + \gamma \cdot U(3,3) - U(2,3)) = \\ &= 0 + 0.1 \cdot (1 + 0.9 \cdot 0 - 0) = 0.1 \end{aligned}$$

$$U(3,3) = 0$$

1	0	0	0
2	0	0	0.1
3	0	-1	1
	1	2	3

Při druhé náhodné procházce $(1,1) \rightarrow (1,2) \rightarrow (2,2) \rightarrow (1,2) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (3,3)$ se změní pouze ohodnocení stavů $(1,3)$ a $(2,3)$:

$$U(1,1) = U(1,1) + \alpha \cdot (r(1,2) + \gamma \cdot U(1,2) - U(1,1)) = 0$$

$$U(1,2) = U(1,2) + \alpha \cdot (r(2,2) + \gamma \cdot U(2,2) - U(1,2)) = 0$$

$$U(2,2) = U(2,2) + \alpha \cdot (r(1,2) + \gamma \cdot U(1,2) - U(2,2)) = 0$$

$$U(1,2) = U(1,2) + \alpha \cdot (r(1,3) + \gamma \cdot U(1,3) - U(1,2)) = 0$$

$$\begin{aligned} U(1,3) &= U(1,3) + \alpha \cdot (r(2,3) + \gamma \cdot U(2,3) - U(1,3)) = \\ &= 0 + 0.1 \cdot (0 + 0.9 \cdot 0.1 - 0) = 0.009 \end{aligned}$$

$$\begin{aligned} U(2,3) &= U(2,3) + \alpha \cdot (r(3,3) + \gamma \cdot U(3,3) - U(2,3)) = \\ &= 0.1 + 0.1 \cdot (1 + 0.9 \cdot 0 - 0.1) = 0.19 \end{aligned}$$

$$U(3,3) = 0$$

1	0	0	0.009
2	0	0	0.190
3	0	-1	1
	1	2	3

Při třetí náhodné procházce $(1,1) \rightarrow (2,1) \rightarrow (1,1) \rightarrow (1,2) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (3,3)$ se změnil ohodnocení stavů $(1,2)$, $(1,3)$ a $(2,3)$:

$$U(1,1) = U(1,1) + \alpha \cdot (r(2,1) + \gamma \cdot U(2,1) - U(1,1)) = 0$$

$$U(2,1) = U(2,1) + \alpha \cdot (r(1,1) + \gamma \cdot U(1,1) - U(2,1)) = 0$$

$$U(1,1) = U(1,1) + \alpha \cdot (r(1,2) + \gamma \cdot U(1,2) - U(1,1)) = 0$$

$$\begin{aligned} U(1,2) &= U(1,2) + \alpha \cdot (r(1,3) + \gamma \cdot U(1,3) - U(1,2)) = \\ &= 0 + 0.1 \cdot (0 + 0.9 \cdot 0.009 - 0) = 0.0008 \end{aligned}$$

$$\begin{aligned} U(1,3) &= U(1,3) + 0.1 \cdot (r(2,3) + 0.9 \cdot U(2,3) - U(1,3)) = \\ &= 0.009 + 0.1 \cdot (0 + 0.9 \cdot 0.19 - 0.009) = \\ &= 0.0252 \end{aligned}$$

$$\begin{aligned} U(2,3) &= U(2,3) + 0.1 \cdot (r(3,3) + 0.9 \cdot U(3,3) - \\ &\quad - U(2,3)) = \\ &= 0.19 + 0.1 \cdot (1 + 0.9 \cdot 0 - 0.19) = 0.271 \end{aligned}$$

$$U(3,3) = 0$$

1	0	0.0008	0.0252
2	0	0	0.271
3	0	-1	1
	1	2	3

Při čtvrté náhodné procházce $(1,1) \rightarrow (2,1) \rightarrow (3,1) \rightarrow (3,2)$ se změni ohodnocení stavů $(3,2)$ a $(3,1)$:

$$U(1,1) = U(1,1) + \alpha \cdot (r(2,1) + \gamma \cdot U(2,1) - U(1,1)) = 0$$

$$U(2,1) = U(2,1) + \alpha \cdot (r(3,1) + \gamma \cdot U(3,1) - U(2,1)) = 0$$

$$\begin{aligned} U(3,1) &= U(3,1) + \alpha \cdot (r(3,1) + \gamma \cdot U(3,2) - U(1,3)) = \\ &= 0 + 0.1 \cdot (-1 + 0.9 \cdot 0) - 0 = -0.1 \end{aligned}$$

$$U(3,2) = 0$$

1	0	0.0008	0.0252
2	0	0	0.271
3	-0.1	-1	1
	1	2	3

Při páté náhodné procházce $(1,1) \rightarrow (1,2) \rightarrow (2,2) \rightarrow (3,2)$ se změní ohodnocení stavů $(1,1)$, $(1,2)$ a $(2,2)$:

$$\begin{aligned} U(1,1) &= U(1,1) + \alpha \cdot (r(1,2) + \gamma \cdot U(1,2) - U(1,1)) = \\ &= 0 + 0.1 \cdot (0 + 0.9 \cdot 0.001 - 0) = 0.00009 \end{aligned}$$

$$\begin{aligned} U(1,2) &= U(1,2) + \alpha \cdot (r(2,2) + \gamma \cdot U(2,2) - U(1,2)) = \\ &= 0.0008 + 0.1 \cdot (0 + 0.9 \cdot 0 - 0.0008) = 0.00072 \end{aligned}$$

$$\begin{aligned} U(2,2) &= U(2,2) + \alpha \cdot (r(3,2) + \gamma \cdot U(3,2) - U(2,2)) = \\ &= 0 + 0.1 \cdot (-1 + 0.9 \cdot 0 - 0) = -0.1 \end{aligned}$$


1	0,00009	0.00072	0.0252
2	0	-0,1	0.271
3	-0.1	-1	1
	1	2	3

Po naučení se pak přechází z libovolného (necílového) stavu do jeho sousedního stavu, který má nejvyšší hodnotu (ale alespoň stejnou hodnotu jako tento stav).

Problém může nastat v případě, kdy stav s penalizací je snadněji dosažitelný, než stav s odměnou. Pak může dojít k takovému ohodnocení jednotlivých stavů, že z některého stavu není dosažitelný žádný jiný stav s vyšším ohodnocením.

Například předchozí problém po několika stech náhodných procházkách může vést k ohodnocení, kdy z počátečního stavu nelze přejít do žádného z obou sousedních stavů (oba mají nižší ohodnocení).

Pozn.: Tento problém se dá někdy odstranit zvýšením počtu procházek, nebo/a snížením koeficientu α .



1	-0.135254	-0.185655	-0.086196
2	-0.205577	-0.419297	0.231171
3	-0.220843	-1	1
	1	2	3

Q learning (Off policy)

Metoda je podobná metodě TD learning, místo hodnocení stavů však hodnotí akce v těchto stavech. K jejich hodnocení používá vztah:

$$Q(s, a) = Q(s, a) + \alpha \left(r(s') + \gamma \max_{a'} Q(s', a') - Q(s, a) \right)$$

kde $Q(s, a)$ označuje ohodnocení akce a provedené ve stavu s a kde výraz

$$\max_{a'} Q(s', a')$$

označuje maximální hodnotu z ohodnocení všech akcí a' , které je možné provést ve stavu s' .

Význam ostatních symbolů je stejný jako u metody TD.

Algoritmus Q learning

1. Zvolte hodnoty koeficientů α a γ ($0 < \alpha \leq 1$; $0 < \gamma \leq 1$) a vynulujte ohodnocení $Q(s,a)$ všech akcí a ve všech stavech s . Dále vynulujte počítadlo procházek $p = 0$ a nastavte jejich maximální počet p_{max} . Nastavte $start \rightarrow s$.
2. Vyberte akci a , která povede k přechodu ze stavu s do stavu s' .
3. Vypočítejte novou hodnotu akce a ve stavu s pomocí vztahu:
$$Q(s, a) = Q(s, a) + \alpha \left(r(s') + \gamma \max_{a'} Q(s', a') - Q(s, a) \right)$$
4. Je-li stav s' cílovým stavem, pak $p+1 \rightarrow p$, $start \rightarrow s$, jinak $s' \rightarrow s$.
5. Je-li $p < p_{max}$, pak se vraťte na bod 2.

Uvažujme podobný příklad jako u metody TD v aktuálním stavu učení ukázaném na obrázku:

Uvažujme stejné cílové stavy i stejné koeficienty $\alpha = 0.1$ a $\gamma = 0.9$.

Pro akce nahoru, doprava, dolů a doleva použijeme symboly L , U , R , D (Left, Up, Right, Down).

Ukážeme si možný výběr akce ve stavu (2,2) a přepoččet jejího ohodnocení.

1	0.12 0.12	0.22 0.36	0.41 0.59	0.18
2	0.25 0.31	0.27 -0.1	0.45 -0.22	0.20
3	0 -1	-1	1	0.77
	1	2	3	

Pokud by agent použil nejlépe ohodnocenou akci, kterou je ve stavu (2,2) akce $Q((2,2),R)$, tak by přešel do stavu (2,3) a nové ohodnocení akce $Q((2,2),R)$ by pak bylo

$$\begin{aligned} Q((2,2),R) &= Q((2,2),R) + \alpha (r(2,3) + \\ &+ \gamma \max(Q((2,3)U), Q((2,3),L), Q((2,3),D)) - Q((2,2),R) = \\ &= 0.45 + 0.1 (0 + 0.9 \max(0.2, -0.22, 0.77) - 0.45) = 0.4743 \end{aligned}$$

Pokud by agent z jakéhokoliv důvodu vybral jinou akci, pak by její ohodnocení bylo

$$\begin{aligned} Q((2,2),U) &= Q((2,2),U) + \alpha (r(1,2) + \\ &+ \gamma \max(Q((1,2)L), Q((1,2), D), Q((1,2),R)) - Q((2,2),U) = \\ &= 0.27 + 0.1 (0 + 0.9 \max(0.22, 0.36, 0.41) - 0.45) = 0.2799 \end{aligned}$$

$$\begin{aligned}
 Q((2,2),L) &= Q((2,2),L) + \alpha (r(2,1) + \\
 &+ \gamma \max(Q((2,1),R), Q((2,1),U), Q((2,1),D)) - Q((2,2),L) = \\
 &= -0.1 + 0.1 (0 + 0.9 \max(0.31, 0.25, -0.26) - 0.1) = -0.0621
 \end{aligned}$$

$$\begin{aligned}
 Q((2,2),D) &= Q((2,2),D) + \alpha (r(3,2) + \gamma (0 - Q((2,2),D)) = \\
 &= -0.57 + 0.1 (-1 + 0.9 \max(0, 0, 0) - 0.57) = -0.613
 \end{aligned}$$

SARSA (On-Policy)

ohodnocuje akce podobně jako Q learning, ale k výběru akcí používá strategii π . Vztah pro přepočítávání ohodnocení akcí

$$Q(s, a) = Q(s, a) + \alpha (r(s') + \gamma Q(s', a') - Q(s, a))$$

Místo hledání maxima z možných následujících akcí $\max_{a'} Q(s', a')$ se používá přímo akce $Q(s', a')$ vybraná také strategií π . Jde tedy o postup s, a, r', s', a' (SARSA).