

12. Principy zpracování přirozeného jazyka

Zpracování přirozeného jazyka (NLP - Natural Language Processing) je problematikou, která zahrnuje dvě relativně samostatné části:

- Zpracování řeči - akustickou analýzu (převod řeči na text) a akustickou syntézu (převod textu na řeč).
- Zpracování textu.

V rámci IZU (tj. v rámci této přednášky) se zaměříme pouze na nejjednodušší základy akustické analýzy a přístupů ke zpracování textu.

Akustická analýza

- Rozpoznávání izolovaně pronesených slov
- Převod spojitě řeči na text

Akustický signál:

10 kHz $\rightarrow$ 20000 vzorků/s

60 dB $\rightarrow$ 10 bitů/vzorek (60 db odpovídá poměru amplitud 1:1000)
 $\Rightarrow 2 \cdot 10^5$ bitů/s

Užitečná informace obsažená v řeči:

10 hlásek/s, 5 bitů/hláška + lingvistická pravidla $\Rightarrow 10 \div 40$ bitů/s

Problém: redukce obrovské redundance řeči.

Pro další zpracování se příznaky (číselné parametry) akustického signálu vyhodnocují na mikrosegmentech o délce 10 – 30 ms, tzn., že například pro vzorkovací frekvenci 10 kHz je v každém mikrosegmentu 200 až 600 vzorků (v dalším textu obecně N vzorků). Pro výpočet parametrů mají vzorky na daném mikrosegmentu buď stejnou váhu (pravoúhlé okénko), nebo vliv vzorků na okrajích segmentu je potlačován (Hammingovo okénko).

- Pravoúhlé okénko:

$$w(m) = \begin{cases} 1 & \text{pro } m \in \langle 0, N-1 \rangle \\ 0 & \text{pro ostatní } m \end{cases}$$

- Hammingovo okénko:

$$w(m) = \begin{cases} 0.54 - 0.46 * \cos(2\pi \cdot m / (N-1)) & \text{pro } m \in \langle 0, N-1 \rangle \\ 0 & \text{pro ostatní } m \end{cases}$$

Příznaky na mikrosegmentech ($x(k)$ je hodnota signálu v čase k):

$$F_i = \frac{1}{N} \sum_{k=-\infty}^{\infty} f(k) * w(n-k)$$

kde

$$n = N * (i - 1)$$

$$n = N * (i - 1) / 2$$

i

pro navazující segmenty

pro překrývající se segmenty

pořadové číslo segmentu (1,2,...)

pro

F_i

$$f(k) = x(k)$$

střední hodnota

$$f(k) = |x(k)|$$

střední absolutní hodnota

$$f(k) = x^2(k)$$

energie (obvykle se měří v několika frekvenčních pásmech)

$$f(k) = (\text{sign}(x(k)) - \text{sign}(x(k-1))) / 2$$

počet průchodů signálu nulou

Další příznaky:

– hodnoty autokorelačních funkcí:

$$F_i(r) = \sum_{k=-\infty}^{\infty} x(k) * w(n-k) * x(k-r) * w(n-k-r)$$

– příznaky z frekvenční oblasti (popis přesahuje rámec IZU):

- DFT/FFT (Discrete/Fast Fourier Transform coefficients)
- LPC (Linear Predictive Coding)
- LPCC (Linear Predictive Cepstral Coefficients)
- MFCC (Mel Frequency Cepstral Coefficients)
- a další

Rozpoznávání izolovaně pronesených slov:

Vzorová (referenční) slova jsou transformována na stejnou časovou délku (stejný počet mikrosegmentů) a na stejnou maximální hlasitost (maximální amplitudu vzorků).

Matice příznaků vyhodnocených na jednotlivých mikrosegmentech jsou pak uloženy v databázi. Matice příznaků pro i -té slovo (N mikrosegmentů, R příznaků na mikrosegmentu) má pak tvar

$$\begin{bmatrix} x_{i11} & x_{i12} & \dots & x_{i1R} \\ x_{i21} & x_{i22} & \dots & x_{i2R} \\ \vdots & & & \vdots \\ x_{iN1} & \dots & \dots & x_{iNR} \end{bmatrix}$$

kde x_{ijk} je k -tý příznak na j -tém mikrosegmentu i -tého slova.

Rozpoznávání nového slova se pak provádí následujícím postupem:

- Určí se začátek a konec tohoto slova (obvykle podle energie mikrosegmentů),
- provede se časová transformace (na stejnou délku, jakou měla upravená vzorová slova),
- provede se amplitudová transformace (na stejnou maximální hlasitost, jakou měla upravená vzorová slova),
- vypočítají se příznaky,
- provede se vlastní rozpoznání:
 - klasickými příznakovými klasifikátory,
 - nebo
 - klasifikátory na bázi dynamického borcení času (Dynamic Time Warping - DTW).


Metoda DTW

rozpoznávané
slovo

·
·
·
·

12,15,14,11,35
13,25, 7, 4,15

1. mikrosegment
5. příznak druhého
mikrosegmentu



17	14				
21	24				
24	7	.	.	.	.
6	4				
14	15				


i-té referenční
slovo

$$D_{11} = |13 - 17| + |25 - 21| + |7 - 24| + |4 - 6| + |15 - 14| = 28$$

$$\mathbf{D}_{12} = |\mathbf{13} - \mathbf{14}| + |\mathbf{25} - \mathbf{24}| + |\mathbf{7} - \mathbf{7}| + |\mathbf{4} - \mathbf{4}| + |\mathbf{15} - \mathbf{15}| = \mathbf{2}$$

$$D_{21} = |12 - 17| + |15 - 21| + |14 - 24| + |11 - 6| + |35 - 14| = 47$$

.....



Převod spojité řeči na text:

Rozpoznání spojité řeči, tj. posloupnosti slov (words) $\mathbf{W}$

$$\mathbf{W} = \mathbf{W}_{1:L} = w_1, w_2, \dots, w_L$$

z posloupnosti vektorů příznaků (features) zjištěných na mikrosegmentech akustického signálu

$$\mathbf{F} = \mathbf{F}_{1:T} = \mathbf{f}_1, \mathbf{f}_2, \dots, \mathbf{f}_T$$

je založeno na výběru takové posloupnosti slov $\hat{\mathbf{W}}$, pro kterou je pravděpodobnost $p(\mathbf{W} | \mathbf{F})$ maximální, tj.

$$\hat{\mathbf{W}} = \underset{\mathbf{W}}{\operatorname{argmax}} \{p(\mathbf{W} | \mathbf{F})\}$$

Protože pravděpodobnost $p(\mathbf{W} | \mathbf{F})$ není přímo zjistitelná, použije se Bayesova vzorce

$$p(\mathbf{W} | \mathbf{F}) = p(\mathbf{F} | \mathbf{W}) p(\mathbf{W}) / p(\mathbf{F})$$

Protože pravděpodobnost $p(F)$ je stejná pro všechny posloupnosti slov, nemá vliv na výběr posloupnosti s maximální pravděpodobností, a proto můžeme tuto složku v předchozím vzorci vypustit. Pak

$$\hat{W} = \underset{W}{\operatorname{argmax}} \{p(W | F)\} = \underset{W}{\operatorname{argmax}} \{p(F | W) p(W)\}$$

Pravděpodobnost $p(F | W)$ se zjišťuje pomocí **akustického modelu** a pravděpodobnost $p(W)$ pomocí **jazykového modelu**.

V plynulém projevu, resp. v jeho akustickém signálu, nelze přímo rozpoznat jednotlivá slova. Rozpoznatelné jsou pouze kratší úseky, které se nazývají fonémy (foném je nejmenší jednotka řeči, která může rozlišovat jednotlivá slova - například záměnou fonému p ve slově *pes* za foném v dostaneme slovo *ves*, které má zcela odlišný význam).

Symoly pro české fonémy z PAC (Phonetic Alphabet for Czech):

Číslo	Foném vyjádřený českými hláskami	Foném dle PAC	Příklad
1	„a“	a	tam
2	„á“	á	táta
3	„b“	b	bába
4	„c“	c	ocel
5	„dz“	C	leckde
6	„č“	č	čichá
7	„dž“	Č	rádža
8	„d“	d	jeden
9	„dʰ“	dʰ	dělat
10	„e“	e	lev
11	„é“	é	méně
12	„f“	f	fauna
13	„g“	g	guma
14	„h“	h	aha
15	„ch“	X	chudý
16	„i“ nebo „y“	i	bil, byl
17	„í“ nebo „ý“	í	vítr, lýko
18	„j“	j	dojat
19	„k“	k	kupec
20	„l“	L	dělá

Číslo	Foném vyjádřený českými hláskami	Foném dle PAC	Příklad
21	„m“	m	máma
22	„m“	M	tramvaj
23	„n“	n	víno
24	„n“	N	banka
25	„ň“	ň	koně
26	„o“	o	kolo
27	„ó“	ó	óda
28	„p“	p	pupen
29	„r“	r	bere
30	„ř“	ř	moře
31	„ř“	Ř	keř
32	„s“	s	sud
33	„š“	š	duše
34	„t“	t	dutý
35	„tʰ“	tʰ	kutil
36	„u“	u	duše
37	„ú“ nebo „ů“	ú	růže
38	„v“	v	láva
39	„z“	z	koza
40	„ž“	ž	růže
41	temné e	E	b, d, s

Foném může mít několik výslovnostních variant, které se nazývají alofóny (například foném *d* se odlišně vyslovuje ve slovech dům a plod). Foném je tedy množina všech podobných zvuků (alofónů), které v daném jazyku představují konkrétní podobu jedné hlásky.

Dělení českých hlásek:

Samohlásky (SA)	a, á, e, é, i, í, o, ó, u, ú									
Znělé párové souhlásky (ZPS)	b	d	d'	g	z	ž	v	h	dz (C)	dž (Č)
Neznělé párové souhlásky (NPS)	p	t	t'	k	s	š	f	ch (X)	c	č
Jedinečné souhlásky (znělé) (JS)	m, n, ň, l, j, r, ř									

Příklad základních přepisovacích pravidel pro česká slova (uvedeno pouze pro informaci o složitosti problému):

$A \rightarrow B / C _ D$ (*if* (řetězci znaků A bezprostředně předchází řetězec znaků C a je bezprostředně následován řetězcem znaků D)
then A se přepíše na řetězec znaků B.

$w \rightarrow v / _$	$q \rightarrow kv / _$	$\check{e} \rightarrow je / \langle b, p, f, v \rangle _$
$d\check{e} \rightarrow d'e / _$	$t\check{e} \rightarrow t'e / _$	$n\check{e} \rightarrow \check{n}e / _$
$d \rightarrow d' / _ \langle i, i' \rangle$	$t \rightarrow t' / _ \langle i, i' \rangle$	$n \rightarrow \check{n} / _ \langle i, i' \rangle$
$\check{e} \rightarrow \check{n}e / m _$	$ex \rightarrow egz / - _ SA$	
$x \rightarrow gz / _ \langle ZPS, JS \rangle$	$x \rightarrow ks / _ \langle NPS, - \rangle$	
$x \rightarrow ks / - _ SA$	$x \rightarrow ks / SA1 _ SA2$	

Řada dalších pravidel existuje pro spodobu znělosti (souhlásky ze skupiny souhlásek párových, například pro výslovnost $b \rightarrow p$, $d \rightarrow t$, $d' \rightarrow t'$, $g \rightarrow k$, atd.) a spodobu artikulační (například pro výslovnost n/N, m/M, atd. z tabulky na snímku 13).


Akustický model

Na snímku 12 bylo uvedeno, že cílem akustického modelu je stanovit pravděpodobnost $p(\mathbf{F} \mid \mathbf{W})$, tj. pravděpodobnost posloupnosti vektorů příznaků $\mathbf{F}$ na základě pravděpodobnosti posloupnosti slov $\mathbf{W}$.

Akustický model obvykle vychází ze skrytého Markovova modelu (HMM Hidden Markov Model):

- V Markovově modelu závisí každý stav s_t pouze na konečném počtu předchozích stavů: $p(s_t) = p(s_t \mid s_{t-1}, s_{t-2}, \dots, s_{t-N+1})$.
- V Markovově modelu 1. řádu závisí každý stav s_t pouze na jediném předchozím stavu: $p(s_t) = p(s_t \mid s_{t-1})$.
- V HMM jsou jednotlivé stavy pozorovatelné pouze nepřímo, prostřednictvím pozorovatelných (Observable) proměnných $\mathbf{o}_t$ s danými podmíněnými pravděpodobnostmi $p(\mathbf{o}_t \mid s_t)$.

HMM – jednoduchý příklad: potřebujete zjistit, jak teplé byly červencové dny v roce 2015 (T - teplé, C - chladné), ale nemůžete nalézt žádné oficiální záznamy. Máte však k dispozici deníček kamarádky, která si v něm poznamenávala počet zmrzlin, které si v každém z těchto dnů zakoupila (1, 2, nebo 3). HMM pak může vypadat například takto:




apriorní pravděpodobnost teplého/chladného dne v červenci (0.8/0.2)

pravděpodobnost, že po teplém dnu bude následovat teplý/chladný den (0.7/0.3) a pravděpodobnost, že po chladném dnu bude následovat teplý/chladný den (0.4/0.6)

pravděpodobnosti počtu zmrzlin kupovaných kamarádkou v teplé a chladné dny (např. pravděpodobnost, že si v teplý den zakoupí pouze jednu zmrzlinu je 0.2)

Uvažujme nyní bez újmy na obecnosti pouze první tři dny, ve kterých si kamarádka postupně zakoupila 2, 1 a 3 zmrzliny. Z hodnot těchto pozorovatelných proměnných máte určit, jak teplé tyto dny byly. Existuje několik přístupů k takové práci s HMM, nejpoužívanější je Viterbiho algoritmus (lze jednoduše znázornit mřížkou, v níž na svislé ose jsou stavy a na vodorovné ose (pro uvažovaný příklad) dny):




$p(\text{TTT} \mid 213) = 0.012544$,


$p(\text{TCT} \mid 213) = 0.00768$, $p(\text{TCC} \mid 213) = 0.00288$, $p(\text{TTC} \mid 213) = 0.001344$

HMM pro jednotlivé fonémy má obvykle tři vnitřní stavy a každý z těchto stavů má několik pozorovatelných stavů o_j – tyto stavy pak představují „modelové“ vektory příznaků pro vektory příznaků f_i zjištěných na mikrosegmentech akustického signálu.

Například HMM pro foném m může vypadat takto:



a HMM pro slovo „vozík“ pak například takto (kroužky značí HMM pro jednotlivé fonémy z obrázku na předchozím snímku, paralelní větve pak různé dialekty (vozík, vozék, vozejk, vozik)):



Podobně se HMM rozšíří pro celé věty, resp. větné celky, u kterých je možné v plynulé řeči identifikovat počátky a konce (na rozdíl od slov).

Jazykový model

Cílem jazykového modelu je určit pravděpodobnost výskytu posloupnosti slov $p(\mathbf{W})$, která se obvykle určuje z velkých slovníků (tzv. korpusů) mluvené řeči.

Pro L slov je pravděpodobnost posloupnosti slov $\mathbf{W}$ obecně dána vztahem

$$p(\mathbf{W}) = \prod_{i=1}^L p(w_i | w_{i-1}, w_{i-2}, \dots, w_1)$$

který se pro delší posloupnosti omezuje na $n-1$ předchozích slov

$$p(\mathbf{W}) = \prod_{i=1}^n p(w_i | w_{i-1}, w_{i-2}, \dots, w_{i-n+1})$$

Zpracování textu

Přístupy ke zpracování textu jsou značně různorodé – od relativně jednoduchých korektur textů, přes dolování znalostí z textů a strojové překlady, až po skutečné porozumění obsahu textu.

Většina přístupů ke zpracování textu je založena na jazykových modelech, které předpovídají pravděpodobnostní rozložení jazykových výrazů.

Nejjednoduššími jazykovými modely jsou distribuce/rozložení pravděpodobností sekvencí znaků. Pro sekvence n znaků se používá název n -gram (resp. unigram pro 1-gram, bigram pro 2-gram a trigram pro 3-gram), formálně je n -gram definován jako Markovův řetězec řádu $n-1$.

Podmíněná pravděpodobnost i -tého znaku c_i je dána výrazem $p(c_i | c_{i-1}, c_{i-2}, \dots, c_1)$, resp. zkráceným výrazem $p(c_i | c_{1:i-1})$ a pro trigram výrazy $p(c_i | c_{i-1}, c_{i-2})$, resp. $p(c_i | c_{i-2:i-1})$.

Pro pravděpodobnost sekvence N znaků v trigramovém modelu pak zřejmě platí

$$p(c_{1:N}) = \prod_{i=1}^N p(c_i | c_{i-2:i-1})$$

Pozn.: Jazyk se 100 znaky má milion různých trigramů a pro přijatelné odhady pravděpodobností $p(c_i | c_{i-2:i-1})$ je zapotřebí text o alespoň 10 000 000 znacích.

Identifikace jazyka je jednou z možných přímých aplikací použití znakových jazykových modelů (dále uvažujeme pouze nejčastěji používané 3-gramové modely).

Ze známých textů se nejprve pro každý uvažovaný jazyk L_k stanoví podmíněné pravděpodobnosti $p(c_i | c_{i-2:i-1}, L_k)$ a pro neznámý text o délce N znaků zřejmě platí

$$p(c_{1:N} | L_k) = \prod_{i=1}^N p(c_i | c_{i-2:i-1}, L_k)$$

Jazyk L^* , ve kterém je s nejvyšší pravděpodobností neznámý text napsán, je pak dán výrazem

$$L^* = \operatorname{argmax}_{L_k} p(L_k | c_{1:N}) = \operatorname{argmax}_{L_k} p(c_{1:N} | L_k) \frac{p(L_k)}{p(c_{1:N})}$$

a protože pravděpodobnost $p(c_{1:N}) = 1$ (neznámý text je daný), pak

$$\begin{aligned} L^* &= \operatorname{argmax}_{L_k} p(c_{1:N} | L_k) p(L_k) = \\ &= \operatorname{argmax}_{L_k} p(L_k) \prod_{i=1}^N p(c_i | c_{i-2:i-1}, L_k) \end{aligned}$$

Apriorní pravděpodobnosti $p(L_k)$ se odhadnou například z náhodně vybraných webových stránek – jejich přesná hodnota není kritická vzhledem k řádovým rozdílům pravděpodobností trigramových modelů.

Znakové jazykové modely se podobným způsobem používají pro *korektury textů*, *klasifikaci textů* (zprávy, právní dokumenty, vědecké dokumenty, apod.), *rozpoznávání vlastních jmen v textech*, atp.

Slovní jazykové modely jsou přirozeným rozšířením znakových modelů. Opět rozeznáváme unigramy, bigramy, trigramy a n -gramy, tentokrát samozřejmě nad slovy. Velký problém je však v tom, že zatímco znaků v daném jazyku jsou řádově desítky až stovky, slov v daném jazyku jsou desítky tisíc až několik milionů. Navíc v některých jazycích, například v čínštině, nejsou slova od sebe oddělena mezerami, což použití slovních jazykových modelů v těchto jazycích prakticky vylučuje.

Pozn.: Pro unigramové slovní modely se často používá anglický název „bag of words“.

Častým použitím slovních jazykových modelů jsou *klasifikace textů*, například klasifikace e-mailů do dvou tříd *spam/ham*, kde *ham* je synonymem pro *not-spam*. Dobrymi indikátory spamu jsou *n*-gramy jako *best drug store*, *millions USD*, *pills for potency*, *pounds of gold* atp.

Formálně:

$$\operatorname{argmax}_{c \in \{spam, ham\}} p(c|message) = \operatorname{argmax}_{c \in \{spam, ham\}} p(message|c) \cdot p(c)$$

kde pravděpodobnosti $p(message|spam)$, $p(message|ham)$, $p(spam)$ a $p(ham)$ lze poměrně snadno určit z počtu spamů a ostatních zpráv v poštovních složkách.

Podobným přístupem lze *kategorizovat texty* například podle žánrů, vědeckých oblastí atp.

Další možnou prací s textem je *vyhledávání informací*. Existuje několik různých přístupů, zřejmě nejpoužívanějším je přístup založený na hodnotící funkci nazvané BM25 (Best Matches 25). Funkce má dva parametry, vyhledávaný výraz a prohledávaný dokument, a vrací číselnou hodnotu, která určuje důležitost dokumentu z pohledu otázky – kombinují se v ní přitom tato tři základní kritéria:

1. Četnost výskytu slov dotazu v prohledávaném dokumentu.
2. Inverzní četnost (eliminace důležitosti častého výskytu spojek, předpon atp).
3. Délku dokumentu (z dokumentů, které obsahují všechna slova dotazu, bývá důležitější dokument kratší).

$$BM25(d_j, q_{1:M}) = \sum_{i=1}^M IDF(q_i) \frac{TF(q_i, d_j)(k + 1)}{TF(q_i, d_j) + k \left(1 - b + b \frac{|d_j|}{L}\right)}$$

$$IDF(q_i) = \log \frac{N - DF(q_i) + 0.5}{DF(q_i) + 0.5}$$

Jednotlivé symboly značí:

d_j	délku j-tého dokumentu (počet slov)
$q_{1:M}$	vyhledávaný výraz skládající se z M slov (q_i je i -té slovo)
N	počet prohledávaných dokumentů
L	průměrnou délka textu v těchto dokumentech
$TF(q_i, d_j)$	četnost výskytu slova q_i (Term Frequency) v dokumentu d_j
$IDF(q_i)$	inverzní četnost výskytu slova q_i
$DF(q_i)$	počet dokumentů (Document Frequency) obsahujících slovo q_i
b, k	parametry (obvykle $b = 0.75$, $k \in [1.2, 2.0]$)

Nejsložitějším přístupem ke zpracování textu je klasický lingvistický přístup, který vede k porozumění obsahu textu a může tak být využit pro *strojové překlady a komunikaci v přirozeném jazyku*.

Podrobnější popis tohoto přístupu překračuje rámec předmětu IZU, a proto jsou dále uvedeny pouze základní informace o syntaktické analýze anglického textu - zpracování češtiny je výrazně složitější vzhledem ke složité morfologii našeho jazyka (k odvozování slov pomocí předpon a přípon).

Syntaktická analýza ověřuje, zda vstupní textový řetězec je větou v daném (přirozeném) jazyce. V kladném případě je výsledkem této analýzy syntaktická struktura věty.

Slovník (lexicon, částečně převzato z Russell, Norvig: AI):

<i>Noun</i> (podstatné jméno)	→ boy [0.05] girl [0.05] plant [0.15] ...
<i>Verb</i> (sloveso)	→ is [0.1] do [0.08] grows [0.1] ...
<i>Adjective</i> (přídavné jm.)	→ right [0.15] blue [0.07] nice [0.05] ...
<i>Adverb</i> (příslovce)	→ here [0,05] ahead [0.06] nearby [0.02] ...
<i>Pronoun</i> (zájmeno)	→ I [0,1] me [0,09] you [0,08] ...
<i>RelPro</i> (relativní zájmeno)	→ that [0.4] which [0.15] who [0.2] ...
<i>Name</i> (jméno)	→ John [0.01] Mary [0.01] Prague [0.002] ...
<i>Article</i> (člen)	→ the [0.4] a [0.3] every [0.05], ...
<i>Prep</i> (předložka)	→ to [0.2] in [0.1] on [0.05] ...
<i>Conj</i> (spojka)	→ and [0.5] or [0.1] but [0.2] ...

Pozn.: Každé slovo může být doplněno pravděpodobností jeho výskytu v dané kategorii uvažovaného slovníku. Součet pravděpodobností výskytu slov v dané kategorii (řádku) musí být samozřejmě roven 1.

Syntaktické kategorie:


<i>S</i>	Sentence (věta),
<i>NP</i>	Noun Phrase (jmenná fráze),
<i>VP</i>	Verb Phrase (slovesná fráze),
<i>ADJS</i>	Adjectives (přídavná jména),
<i>PP</i>	Prepositional Phrase (předložková fráze),
<i>RelClause</i>	Relative Clause (relativní klauzule)

Gramatika (přepisovací pravidla):

<i>S</i>	→	<i>NP VP</i>	[0.9]	I + feel a breeze
		<i>S Conj S</i>	[0.1]	I feel a breeze + and + it stinks
<i>NP</i>	→	<i>Pronoun</i>	[0.3]	I
		<i>Name</i>	[0.1]	Mary
		<i>Noun</i>	[0.1]	stone
		<i>Article Noun</i>	[0.25]	the box
		<i>Article ADJS Noun</i>	[0.05]	the big red box
		<i>NP PP</i>	[0.1]	the box + on the table
		<i>NP RelClause</i>	[0.1]	the liquid + that is smelly

<i>VP</i>	→	<i>Verb</i>	[0.4]	shows
		<i>Vp Np</i>	[0.35]	feel + a breeze
		<i>VP Adjective</i>	[0.05]	is red
		<i>VP PP</i>	[0.1]	is + on the box
		<i>VP Adverb</i>	[0.1]	go ahead
<i>ADJS</i>	→	<i>Adjective</i>	[0.8]	smelly
		<i>Adjective ADJS</i>	[0.1]	big + red
<i>PP</i>	→	<i>Prep NP</i>	[1]	to + the table
<i>RelClause</i>	→	<i>RelPro VP</i>	[1]	that + is big

Například pravděpodobnost věty „Every plant grows.“ se pak snadno určí pomocí derivačního stromu



v lineárním zápisu [S [NP [Article every] [noun plant]] [VP [verb grows]]]:

$$p(S) = 0.9 \cdot 0.25 \cdot 0.05 \cdot 0.15 \cdot 0.4 \cdot 0.1 = 0.0000675.$$

Pozn: Tyto pravděpodobnosti se pak mohou využít při hodnocení různých významů jedné věty.

Rozšířené gramatiky (Augmented grammars) řeší problém předchozích bezkontextových gramatik spočívající v tom, že vztahy NP a VP nejsou nezávislé. Například věta *John eats banana* je jistě pravděpodobnější, než věta *John eats bandana*, protože John bude často jíst banány, ale pravděpodobně nikdy nebude jíst šátek.

Rozšíření gramatiky pak spočívá v tom, že se v přepisovacích pravidlech uvádí pravděpodobnosti pro konkrétní slova, například

$$VP(v) \rightarrow Vp(v) Np(n) [p(v,n)]$$

kde pravděpodobnost $p(eats, banana) \gg p(eats, bandanna)$.

Pozn.: problémem předchozího přístupu je velmi velké množství potřebných odhadů $p(v,n)$. Například pro slovník s 20 000 podstatnými jmény a 5 000 slovesy je zapotřebí 1000000 těchto odhadů.

Další problém, který je řešitelný pomocí rozšířených gramatik jsou anglická osobní zájmena (záleží zda jsou na místě podmětu, nebo předmětu). Pak se přepisovací pravidla mohou upravit takto:

<i>S</i>	→	<i>NP(subjective) VP</i>
<i>NP(Case)</i>	→	<i>Pronoun(Case) Name Noun ...</i>
<i>VP</i>	→	<i>Verb Verb NP(objective) ...</i>
<i>PP</i>	→	<i>Prep NP(objective)</i>
.		
.		
<i>Pronoun(subjective)</i>	→	<i>I you he she it ...</i>
<i>Pronoun(objective)</i>	→	<i>me you him her it ...</i>

Přetrvávající problémy:

- Čas (minulý, přítomný, budoucí, ...)
- Lexikální, syntaktická a sémantická nejednoznačnost (slovo má více významů, existuje více správných syntaktických rozkladů, existuje více správných sémantických významů)
- Metafory
- ...